Học viện Công nghệ Bưu chính Viễn thông
Khoa Công nghệ Thông tin

Intelligent System Development — Assignment 08

Neo4j và RAG

trong tra cứu thông tin về đái tháo đường

Trần Xuân Thành

Mã sinh viên: B23DCAT280 · Lớp: E23CNPM01 · Nhóm: 02

Giảng viên hướng dẫn: Dinh Que Tran, Ph.D., Assoc. Prof.

Học kỳ I.2026

Tóm tắt

Bài làm xây dựng một ứng dụng web hỏi đáp về đái tháo đường. Tri thức được thu thập từ 35 tài liệu công khai của 16 đơn vị xuất bản (13 tiếng Việt, 22 tiếng Anh), chia thành 424 đoạn văn và tổ chức thành đồ thị tri thức `KB_diabet` trên Neo4j. Đồ thị gồm 2.846 nút và 5.027 quan hệ, trong đó 1.779 mục dữ kiện y tế (triệu chứng, biến chứng, yếu tố nguy cơ, khuyến nghị, nhóm thuốc) đều nối về đúng đoạn văn chứa câu trích làm bằng chứng. Phần hỏi đáp dùng kỹ thuật RAG: tìm đoạn văn liên quan, gửi kèm câu hỏi cho mô hình ngôn ngữ, rồi kiểm tra trích dẫn trước khi hiển thị. Trên bộ 30 câu kiểm tra, hệ thống trả lời 25/26 câu trong phạm vi, 97,9% phát biểu được nguồn trích dẫn hỗ trợ và từ chối đúng 100% câu ngoài phạm vi. Phần phân loại huấn luyện mạng MLP trên 686.019 bản ghi khảo sát BRFSS 2015 và 2023; nhãn dự đoán được dùng để chọn chủ đề tra cứu, không dùng để chẩn đoán.

Mục lục

1 Giới thiệu **3**
- 1.1 Mục tiêu và phạm vi . . . 3
- 1.2 Kết quả chính . . . 3

2 Dữ liệu **4**
- 2.1 Nguồn tri thức y tế . . . 4
- 2.2 Thu thập và làm sạch . . . 4
- 2.3 Dữ liệu khảo sát BRFSS . . . 5
- 2.4 Đặc trưng đầu vào . . . 6
- 2.5 Tiền xử lý và chia tập . . . 6

3 Thiết kế hệ thống **7**
- 3.1 Lược đồ tri thức . . . 7
- 3.2 Trích dữ kiện y tế có kiểm chứng . . . 7
- 3.3 Dữ liệu khảo sát trên đồ thị . . . 8
- 3.4 Kiến trúc xử lý . . . 8

4 Hệ thống hỏi đáp RAG **9**
- 4.1 Truy xuất nội dung . . . 9
- 4.2 Sinh câu trả lời và kiểm trích dẫn . . . 9
- 4.3 Phương pháp đánh giá . . . 10

5 Thực nghiệm phân loại **10**
- 5.1 Môi trường và cấu hình . . . 10
- 5.2 Chỉ số . . . 11
- 5.3 So sánh mô hình . . . 11
- 5.4 Kết quả ba nhóm khảo sát . . . 11
- 5.5 Kết quả Type 1 / Type 2 . . . 12
- 5.6 Hiệu chỉnh xác suất . . . 13

6 Kết quả hỏi đáp **13**
- 6.1 So sánh các cách truy xuất . . . 13
- 6.2 Đóng góp của đồ thị . . . 14
- 6.3 Chất lượng câu trả lời . . . 14

7 Tích hợp và thảo luận **15**
- 7.1 Phân loại và chọn chủ đề . . . 15
- 7.2 Giới hạn và hướng phát triển . . . 16

8 Kết luận **16**

9 Tài liệu tham khảo **16**

1. Giới thiệu

1.1 Mục tiêu và phạm vi

Bài toán. Người bệnh và người nhà thường tìm thông tin về đái tháo đường trên mạng. Nguồn tin nhiều, chất lượng không đều, và một câu khuyến nghị bị tách khỏi điều kiện áp dụng của nó có thể gây hiểu sai. Bài làm đặt ra yêu cầu cho hệ thống tra cứu như sau: *mọi ý trong câu trả lời phải chỉ được về một đoạn văn cụ thể trong một tài liệu cụ thể*, và khi kho tài liệu không có thông tin thì hệ thống phải nói rõ là không có, thay vì đoán.

Để đáp ứng yêu cầu đó, bài làm kết hợp ba thành phần:

- **Đồ thị tri thức trên Neo4j.** Neo4j là hệ quản trị cơ sở dữ liệu đồ thị: dữ liệu được lưu thành nút (đối tượng) và quan hệ có hướng giữa các nút. Bệnh, triệu chứng, khuyến nghị, đoạn văn và tài liệu đều là nút; câu "khuyến nghị này được đoạn văn kia hỗ trợ" là một quan hệ.
- **RAG** (Retrieval-Augmented Generation, sinh câu trả lời có truy xuất). Thay vì để mô hình ngôn ngữ trả lời từ trí nhớ, chương trình tìm các đoạn văn liên quan trước, rồi yêu cầu mô hình chỉ dùng các đoạn đó.
- **Bộ phân loại khảo sát.** Một mạng nơ-ron nhiều lớp (MLP) dự đoán nhóm tình trạng từ câu trả lời khảo sát sức khỏe; nhãn dự đoán dẫn người dùng tới chủ đề tra cứu phù hợp.

1.2 Kết quả chính

25/26	**97,9%**	**100%**	**2,46 s**
câu trong phạm vi được trả lời	phát biểu được nguồn hỗ trợ	câu ngoài phạm vi bị từ chối	trung vị thời gian một câu

Bảng 1: Các chức năng của hệ thống và cách thực hiện

Chức năng	Cách thực hiện
Thu thập tri thức	Tải trang web và PDF, trích văn bản, lọc menu và quảng cáo, chia đoạn.
Tổ chức tri thức	Lưu tài liệu, đoạn văn và dữ kiện y tế trên Neo4j; mỗi dữ kiện có quan hệ `SUPPORTED_BY` tới đoạn chứa câu trích.
Hỏi đáp	Tìm đoạn gần nghĩa bằng vector, mở rộng qua đồ thị, mô hình `gemma-4` viết câu trả lời có trích dẫn, chương trình kiểm trích dẫn.
Phân loại và tra cứu	MLP dự đoán nhóm từ 19 câu trả lời khảo sát; bảng chủ đề chuyển nhãn thành chủ đề tra cứu.
Giao diện web	Ứng dụng Next.js dựng lại từ dự án P-185: trang hỏi đáp, trang đồ thị, trang phân loại.

Hệ thống là công cụ tra cứu thông tin tham khảo. Nhãn của bộ phân loại dựa trên câu trả lời tự báo cáo, không phải kết quả xét nghiệm, và không được dùng để chẩn đoán hay chỉ định điều trị cho một người cụ thể. Mỗi câu trả lời trên giao diện đều kèm lời nhắc này.

2. Dữ liệu

2.1 Nguồn tri thức y tế

Đơn vị xuất bản. Kho gồm 35 tài liệu: 10 trang web và 3 PDF tiếng Việt, 18 trang web và 4 PDF tiếng Anh. Nguồn tiếng Việt gồm ba hướng dẫn chẩn đoán và điều trị của Bộ Y tế (đái tháo đường típ 2, tiền đái tháo đường, đái tháo đường típ 1 ở trẻ em), trang của các bệnh viện và Viện Dinh dưỡng Quốc gia. Nguồn tiếng Anh gồm NIDDK (viện nghiên cứu tiểu đường, tiêu hóa và thận của Hoa Kỳ), WHO, NHS (Anh), NDSS (Úc), MedlinePlus, Diabetes UK, Hiệp hội Đái tháo đường Hoa Kỳ và Bộ Y tế Hồng Kông.

Bảng 2: Số tài liệu theo đơn vị xuất bản

Đơn vị xuất bản	Tài liệu
NIDDK	5
NHS	4
American Diabetes Association	3
Bộ Y tế	3
Bệnh viện TWQĐ 108	2
Bệnh viện Tâm Anh	2
Diabetes UK	2
Hong Kong Department of Health	2
MedlinePlus	2
NDSS	2
Vinmec	2
WHO	2
Medlatec	1
Nhà thuốc Long Châu	1
Sức khỏe & Đời sống (Bộ Y tế)	1
Viện Dinh dưỡng Quốc gia	1

Nguồn không đưa vào được. Các trang của CDC (Hoa Kỳ) trả mã lỗi 403 cho chương trình tải tự động; bài làm tôn trọng lệnh chặn này và không đưa CDC vào kho. Đường dẫn gốc của các quyết định Bộ Y tế trên cổng kcb.vn trả lỗi 404, nên văn bản được lấy từ bản đăng lại trên website bệnh viện, cùng số quyết định. Một trang giải thích HbA1c bị loại vì ghi nhầm ngưỡng 5,7–6,4% là đái tháo đường, trong khi đây là ngưỡng tiền đái tháo đường.

2.2 Thu thập và làm sạch

Tải dữ liệu. Danh sách nguồn nằm trong `pipeline/sources.yaml`, mỗi nguồn có mã, địa chỉ, đơn vị xuất bản, ngôn ngữ và loại tệp. Chương trình tải bản gốc vào `data/raw/` và ghi mã băm SHA-256 của từng tệp. Lần chạy sau bỏ qua tệp đã có cùng mã băm, nên chạy lại không tải lại và cho cùng kết quả.

Trích văn bản và chia đoạn. Trang web được trích bằng thư viện trafilatura, PDF được trích theo từng trang. Sau đó chương trình bỏ các dòng khớp danh sách mẫu trong `pipeline/boilerplate.txt` (menu, nút chia sẻ, "đặt lịch khám", số tổng đài) và bỏ các đoạn trùng nhau giữa các trang. Văn bản được chia thành đoạn khoảng 350 token, gối nhau 50 token, cắt ở ranh giới đoạn văn. Token là đơn vị văn bản mà mô hình xử lý, có thể là một

từ hoặc một phần của từ; số token được đếm bằng bộ tách từ của chính mô hình biểu diễn bge-m3 để đoạn không vượt giới hạn đầu vào.

Bảng 3: Kiểm kê nội dung sau làm sạch

Đối tượng	Số lượng	Ghi chú
Tài liệu (tiếng Việt / tiếng Anh)	13 / 22	16 đơn vị xuất bản
Đoạn văn (tiếng Việt / tiếng Anh)	273 / 151	tổng 424 đoạn
Độ dài đoạn (token)	337	nhỏ nhất 63, lớn nhất 400
Câu hỏi kiểm tra	30	26 trong phạm vi, 4 ngoài phạm vi

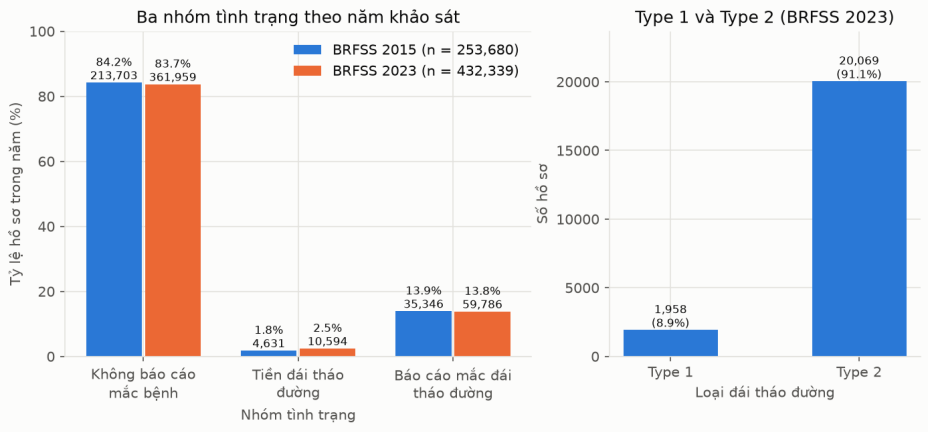
Giới hạn của bước làm sạch. Phần lớn đoạn tiếng Việt đến từ ba PDF hướng dẫn của Bộ Y tế. Một số chữ trong các PDF này bị tách sai do phông chữ nhúng thiếu ký tự (ví dụ "dinh dư ng"), và bảng biểu bị trích thành các cột xen kẽ nhau. Kiểm tra 30 đoạn ngẫu nhiên (`results/chunk_audit.md`) không thấy đoạn nào là menu, quảng cáo hay đoạn rỗng.

2.3 Dữ liệu khảo sát BRFSS

Hai bài toán phân loại. BRFSS là khảo sát hành vi và sức khỏe qua điện thoại hằng năm của CDC. Bài làm dùng hai năm: bộ 2015 đã được chuẩn hóa sẵn (253.680 dòng, nhãn `Diabetes_012`) và tệp gốc năm 2023 (LLCP2023, tải trực tiếp từ trang dữ liệu công khai của CDC). Từ năm 2023, chương trình dựng lại cùng nhãn `Diabetes_012` từ câu hỏi `DIABETE4`: 0 là không báo cáo mắc bệnh (gồm trường hợp chỉ mắc khi mang thai), 1 là tiền đái tháo đường, 2 là báo cáo mắc đái tháo đường. Bài toán thứ hai dùng câu hỏi `DIABTYPE` của năm 2023, chỉ có ở người đã báo cáo mắc bệnh: 1 là Type 1, 2 là Type 2.

Bảng 4: Nhãn và số mẫu nguồn

Bài toán	Nhãn	Số dòng
Ba nhóm, năm 2015	0 / 1 / 2	213.703 / 4.631 / 35.346
Ba nhóm, năm 2023	0 / 1 / 2	361.959 / 10.594 / 59.786
Ba nhóm, tổng		686.019
Type 1/2, năm 2023	1 / 2	1.958 / 20.069



Hình 1: Phân bố nhãn của hai bài toán. Nhóm tiền đái tháo đường và nhóm Type 1 rất ít mẫu.

Cả hai bộ nhãn đều là câu trả lời tự báo cáo, không có xét nghiệm xác nhận. Nhóm tiền đái tháo đường chiếm khoảng 2% số dòng, trong khi theo các nguồn y tế tỷ lệ thật cao hơn

nhiều; phần lớn người có tiền đái tháo đường không biết mình mắc. Vì vậy nhãn 1 ở đây là "người đã được bác sĩ thông báo có tiền đái tháo đường", không phải "người có tiền đái tháo đường".

2.4 Đặc trưng đầu vào

Mỗi dòng có 19 đặc trưng: huyết áp cao, cholesterol cao, đã kiểm tra cholesterol, BMI, hút thuốc, đột quỵ, bệnh tim, hoạt động thể lực, uống nhiều rượu, có bảo hiểm y tế, không đi khám vì chi phí, tự đánh giá sức khỏe, số ngày sức khỏe tinh thần và thể chất không tốt trong 30 ngày, khó đi lại, giới tính, nhóm tuổi, học vấn, thu nhập. BMI (chỉ số khối cơ thể) bằng cân nặng (kg) chia bình phương chiều cao (m).

Ghép hai năm. Bộ 2015 có thêm hai cột ăn trái cây và ăn rau. Tệp năm 2023 không có câu hỏi này trong bộ 350 biến, nên hai cột bị bỏ ở cả hai năm để mô hình nhận cùng đầu vào. Các biến năm 2023 được mã lại theo quy ước năm 2015, ví dụ `_BMI5` chia 100 thành BMI thật, thu nhập 11 mức của `INCOME3` gộp mức 8–11 thành mức 8; mã 7 (không biết) và 9 (từ chối) chuyển thành giá trị thiếu. Toàn bộ bảng mã lại được lưu trong `results/classifier.json`.

Tránh lộ nhãn ở bài Type 1/2. Các câu hỏi `DIABETE4`, `DIABAGE4` (tuổi khi được chẩn đoán) và `INSULIN1` (đang dùng insulin) bị loại khỏi đầu vào. Câu hỏi dùng insulin gần như trả lời thẳng câu hỏi Type 1 hay Type 2, nên nếu giữ lại thì mô hình đạt điểm cao mà không học được gì từ các đặc trưng còn lại.

2.5 Tiền xử lý và chia tập

Chia theo hồ sơ. Hồ sơ là toàn bộ giá trị đặc trưng của một dòng. Bộ ba nhóm có 686.019 dòng nhưng chỉ 634.636 hồ sơ khác nhau. Nếu chia ngẫu nhiên từng dòng, hai dòng giống hệt nhau có thể rơi vào tập huấn luyện và tập kiểm tra, và mô hình được chấm trên đầu vào nó đã thấy. Chương trình gom các dòng cùng hồ sơ thành nhóm, thử 32 cách gán nhóm vào ba tập theo tỷ lệ 70/15/15 và chọn cách có tỷ lệ từng lớp gần mục tiêu nhất; kiểm thử `tests/test_split.py` khẳng định không hồ sơ nào nằm ở hai tập.

Điền thiếu và chuẩn hóa. Giá trị thiếu được điền bằng trung vị của cột trên tập huấn luyện, sau đó mỗi cột được chuẩn hóa

$$z = \frac{x - \mu}{\sigma},$$

với μ và σ là trung bình và độ lệch chuẩn của cột trên tập huấn luyện. Tập xác thực và kiểm tra dùng lại đúng các thông số này; tính lại trên dữ liệu kiểm tra sẽ để lọt thông tin của tập kiểm tra vào bước học.

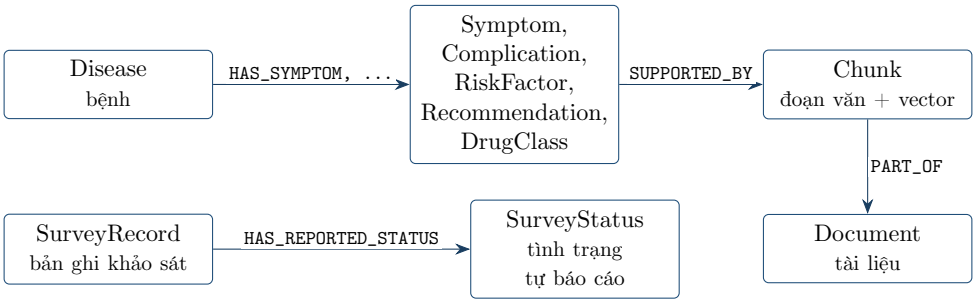
Bảng 5: Số dòng và phân bố nhãn của từng tập (seed 0)

Bài toán / tập	Tổng	Nhãn 0 / 1 / 2 hoặc 1 / 2
Ba nhóm / huấn luyện	480.360	403.091 / 10.647 / 66.622
Ba nhóm / xác thực	102.353	85.826 / 2.283 / 14.244
Ba nhóm / kiểm tra	103.306	86.745 / 2.295 / 14.266
Type 1/2 / huấn luyện	15.397	1.369 / 14.028
Type 1/2 / xác thực	3.334	291 / 3.043
Type 1/2 / kiểm tra	3.296	298 / 2.998

3. Thiết kế hệ thống

3.1 Lược đồ tri thức

Nút và quan hệ. Lược đồ quy định các loại nút, thuộc tính và quan hệ được phép. Toàn bộ lược đồ nằm trong một tệp `backend/app/schema.py`; chương trình nạp dữ liệu, chương trình truy xuất và kiểm thử đều đọc từ tệp này, nên đổi lược đồ ở một chỗ là đủ. Mọi nút mang thuộc tính `kb_id = "KB_diabet"` để phân biệt với dữ liệu khác trong cùng cơ sở dữ liệu, và mỗi nhãn có ràng buộc duy nhất trên mã `id`.



Hình 2: Lược đồ đồ thị `KB_diabet`. Quan hệ `SUPPORTED_BY` mang thuộc tính `quote`: câu trích nguyên văn.

Bảng 6: Số nút theo nhãn

Nhãn	Số nút
Chunk	424
Complication	257
Disease	5
Document	35
DrugClass	191
Recommendation	840
RiskFactor	275
SurveyRecord	600
SurveyStatus	3
Symptom	216

Bảng 7: Số quan hệ theo loại

Quan hệ	Số lượng
`HAS_COMPLICATION`	277
`HAS_DRUG_CLASS`	208
`HAS_RECOMMENDATION`	868
`HAS_REPORTED_STATUS`	600
`HAS_RISK_FACTOR`	298
`HAS_SYMPTOM`	236
`PART_OF`	424
`SUPPORTED_BY`	2.116

3.2 Trích dữ kiện y tế có kiểm chứng

Mỗi đoạn văn được gửi cho mô hình ngôn ngữ `gemma-4` kèm yêu cầu liệt kê các dữ kiện đoạn nêu rõ, ở dạng JSON: loại dữ kiện, bệnh liên quan, tên ngắn tiếng Việt, điều kiện áp dụng nếu có, và một câu trích nguyên văn từ đoạn. Mô hình ngôn ngữ có thể bịa câu trích, nên chương trình không tin kết quả này mà kiểm lại bằng code: câu trích phải là một chuỗi con của đoạn văn sau khi chuẩn hóa khoảng trắng và chữ hoa. Dữ kiện không qua bước kiểm bị loại và ghi vào `results/facts_rejected.jsonl`.

> Trên toàn kho, mô hình đề xuất 2.195 dữ kiện. Chương trình giữ 2.124, loại 60 dữ kiện có câu trích không nằm trong đoạn và 11 dữ kiện sai loại hoặc sai mã bệnh. Bước này tốn 522.949 token.

Dữ kiện trùng tên được gộp thành một nút, kể cả khi đến từ hai nguồn khác nhau; một bảng đồng nghĩa nhỏ (`pipeline/synonyms.yaml`) gộp các cách gọi khác nhau như "khát nước

nhiều" và "khát nhiều". Khi một khuyến nghị được nhiều nguồn cùng nêu, nút khuyến nghị có nhiều quan hệ `SUPPORTED_BY`, mỗi quan hệ tới một đoạn văn. Ví dụ nút "giảm cân nếu thừa cân và duy trì cân nặng đó" được cả NIDDK và NDSS hỗ trợ.

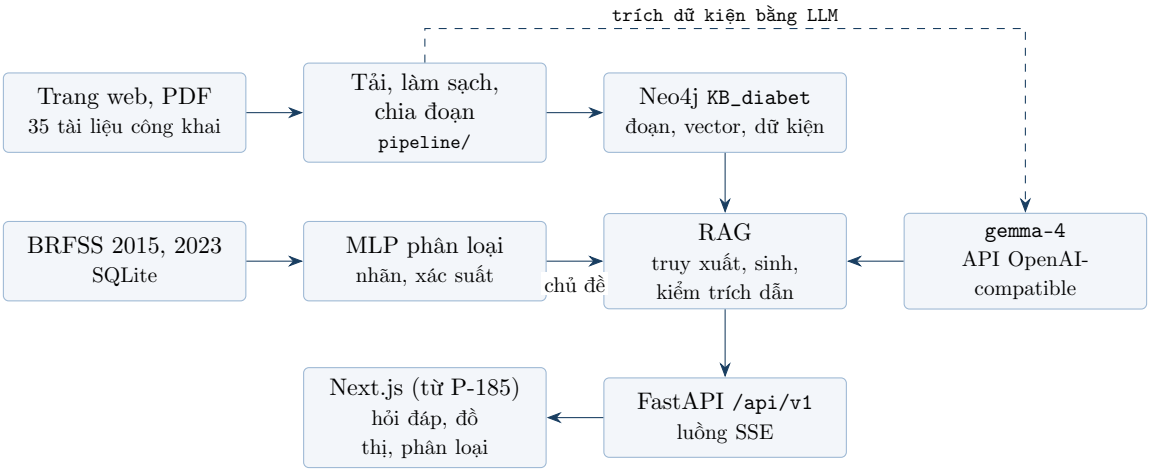
Giới hạn. Tên ngắn do mô hình đặt không thống nhất giữa các lần gọi, nên việc gộp còn yếu: trong 1.779 dữ kiện chỉ 52 dữ kiện được nguồn của cả hai ngôn ngữ cùng hỗ trợ. Một số dữ kiện bị gán sai loại, ví dụ cụm "không cần liệu pháp insulin" bị xếp vào triệu chứng của đái tháo đường típ 2. Bước kiểm câu trích đảm bảo dữ kiện có trong nguồn, nhưng không kiểm được dữ kiện có được phân loại đúng hay không.

3.3 Dữ liệu khảo sát trên đồ thị

Bộ khảo sát được nạp vào tệp SQLite `data/survey.db` gồm bảng `survey_records` (mã dòng, năm, nhãn, bài toán và các đặc trưng dạng JSON) và bảng `status_definitions` (mô tả nhãn). Chương trình lấy tối đa 100 dòng đầu cho mỗi cặp năm và nhãn, tạo nút `SurveyRecord` và nối tới nút `SurveyStatus` tương ứng. Lệnh `MERGE` của Neo4j tìm nút theo khóa và chỉ tạo khi chưa có, nên chạy lại không sinh nút trùng; kiểm thử `tests/test_ingest_idempotent.py` chạy nạp hai lần và so số nút.

Mẫu 600 dòng trên đồ thị chỉ minh họa luồng nạp dữ liệu quan hệ. Hai bộ phân loại được huấn luyện trên toàn bộ dữ liệu.

3.4 Kiến trúc xử lý



Hình 3: Kiến trúc thu thập, phân loại và hỏi đáp.

Kế thừa từ P-185. Kiến trúc và giao diện được dựng lại từ P-185, một trợ lý tra cứu pháp luật thuế cùng dạng bài toán (câu trả lời phải có căn cứ trích dẫn). Bài làm giữ lại các phần dùng chung được: hợp đồng sự kiện SSE giữa máy chủ và trình duyệt, bộ phân tích luồng sự kiện phía trình duyệt, khung trò chuyện, bảng nguồn, hệ màu và phông chữ. Các phần gắn với nghiệp vụ thuế (tờ khai, máy tính thuế, phân quyền kế toán, hiệu lực văn bản) và các phần không cần cho bài (PostgreSQL, đăng nhập, LangGraph) được bỏ. Phía máy chủ được viết lại gọn; mã giao diện còn khoảng 3.400 dòng so với khoảng 44.000 dòng của bản gốc.

Luồng sự kiện SSE. SSE (Server-Sent Events) là cách máy chủ gửi dần từng sự kiện qua một kết nối HTTP. Một lượt hỏi phát lần lượt `stream.started`, `sources.snapshot` (các đoạn đã tìm được), `answer.started`, các sự kiện `answer.text.delta` và `answer.citation`, `answer.final` (câu trả lời đầy đủ) và `stream.completed`. Kiểm thử phía giao diện so danh sách tên sự kiện với `schema.py` để hai phía không lệch nhau.

4. Hệ thống hỏi đáp RAG

4.1 Truy xuất nội dung

Biểu diễn văn bản. Biểu diễn số (embedding) chuyển một đoạn văn thành vector, tức một dãy số có thứ tự. Bài làm dùng mô hình `BAAI/bge-m3`, tạo vector 1.024 số cho mỗi đoạn, được huấn luyện để câu hỏi và đoạn văn cùng nghĩa có vector gần nhau kể cả khi khác ngôn ngữ. Vector được lưu ngay trên thuộc tính `embedding` của nút `Chunk` và đánh chỉ mục vector của Neo4j, nên không cần một cơ sở dữ liệu vector riêng. Độ gần được đo bằng cosine:

$$\cos(u, v) = \frac{\sum_i u_i v_i}{\sqrt{\sum_i u_i^2}\,\sqrt{\sum_i v_i^2}}.$$

Các vector được chuẩn hóa về độ dài 1, nên cosine bằng tích vô hướng.

Ba nhánh truy xuất. Chương trình có ba cách tìm đoạn văn:

- **BM25**: chấm điểm theo số từ chung giữa câu hỏi và đoạn, có trọng số cho từ hiếm.
- **Vector**: lấy 20 đoạn có cosine cao nhất qua chỉ mục vector của Neo4j.
- **Đồ thị**: từ các đoạn tốt nhất, đi theo `SUPPORTED_BY` tới dữ kiện rồi đi tiếp tới các đoạn khác hỗ trợ cùng dữ kiện; nếu biết chủ đề, lấy thêm các đoạn hỗ trợ dữ kiện của bệnh tương ứng.

Khi dùng nhiều nhánh, danh sách được gộp bằng RRF (Reciprocal Rank Fusion): đoạn ở hạng r của một nhánh nhận điểm $1/(k + r)$ với $k = 60$, và điểm của đoạn là tổng điểm qua các nhánh.

Cấu hình được chọn. Mục 6.1 cho thấy xếp hạng chỉ bằng vector cho kết quả tốt nhất, và đưa đồ thị vào làm một nhánh xếp hạng ngang hàng làm kết quả kém đi. Vì vậy cấu hình chạy thật xếp hạng bằng vector, lấy 5 đoạn đầu, rồi dùng đồ thị theo hai cách không làm xáo trộn thứ hạng: gắn các dữ kiện (kèm điều kiện áp dụng) của mỗi đoạn vào ngữ cảnh, và nối thêm tối đa 2 đoạn liên kết qua dữ kiện chung vào sau 5 đoạn đầu.

4.2 Sinh câu trả lời và kiểm trích dẫn

Lời nhắc. Các đoạn được đánh nhãn S1, S2, ... và gửi cho mô hình cùng câu hỏi. Lời nhắc yêu cầu chỉ dùng thông tin trong nguồn, đặt dấu `[[cite:Sn]]` sau mỗi ý, giữ nguyên điều kiện áp dụng, không thêm liều thuốc hay con số không có trong nguồn, và viết đúng một dòng `KHONG_DU_BANG_CHUNG` khi nguồn không trả lời được câu hỏi.

Cổng trích dẫn. Trước khi hiển thị, chương trình chuẩn hóa mọi cách viết trích dẫn của mô hình (`[[S5]]`, `[S1]`, `[[1, 3]]`) về một dạng, bỏ các trích dẫn trỏ tới nguồn không được cung cấp, và chuyển câu trả lời không còn trích dẫn hợp lệ nào thành trạng thái `insufficient_evidence`. Câu hỏi có cosine cao nhất dưới 0,78 được coi là ngoài phạm vi và bị từ chối mà không gọi mô hình. Vì cổng chạy trên toàn bộ câu trả lời, máy chủ đợi mô hình viết xong rồi mới phát các đoạn chữ; người dùng không bao giờ thấy một ý chưa qua kiểm tra.

Bảng 8: Ba trạng thái câu trả lời

Trạng thái	Ý nghĩa
`answered`	Có ít nhất một trích dẫn hợp lệ; giao diện hiện phần trả lời và phần căn cứ.
`insufficient_evidence`	Câu hỏi trong lĩnh vực nhưng nguồn tìm được không trả lời được.
`out_of_scope`	Câu hỏi không gần nội dung nào của kho; không gọi mô hình ngôn ngữ.

4.3 Phương pháp đánh giá

Bộ câu hỏi. Bộ đánh giá gồm 30 câu: 26 câu trong phạm vi (khái niệm, triệu chứng, nguy cơ, chẩn đoán, ăn uống, vận động, thuốc, biến chứng, tổng hợp; trong đó 4 câu tiếng Anh) và 4 câu ngoài phạm vi, gồm hai câu gần lĩnh vực (ung thư tuyến tụy, thuốc cảm cúm).

Tham chiếu theo nội dung. Với mỗi câu, chương trình gộp 20 đoạn đầu của mọi nhánh truy xuất (trung bình 48 đoạn), và mô hình ngôn ngữ chấm từng đoạn có chứa câu trả lời trực tiếp hay không. Bộ chấm phải trích nguyên văn câu trả lời trong đoạn, và chương trình kiểm câu trích có thật trong đoạn. Kết quả là 269 cặp câu hỏi và đoạn liên quan, từ 2 đến 21 đoạn mỗi câu, bằng cả hai ngôn ngữ. Đọc lại 12/15 nhãn dương ngẫu nhiên thấy khớp với đánh giá của người đọc; trước khi thêm bước kiểm câu trích, tỷ lệ này chỉ khoảng 15–17/25.

Chỉ số truy xuất. Với R là tập đoạn liên quan và T_k là k đoạn đầu chương trình trả về:

$$\text{Hit@}k = \mathbb{1}[\,|R \cap T_k| > 0\,], \qquad \text{Precision@}k = \frac{|R \cap T_k|}{k},$$

$$\text{Recall@}k = \frac{|R \cap T_k|}{\min(|R|, k)}, \qquad \text{MRR} = \frac{1}{\text{hạng của đoạn liên quan đầu tiên}}.$$

Recall@k chia cho $\min(|R|, k)$ thay vì $|R|$: một câu có 20 đoạn liên quan thì 5 kết quả đầu không thể chứa đủ 20, và chia cho 20 sẽ phạt hệ thống vì điều nó không làm được. Ví dụ với $R = \{a, b\}$ và kết quả $\{a, c, d\}$: Hit@3 = 1, Precision@3 = 1/3, Recall@3 = 1/2, MRR = 1 (kiểm thử `tests/test_metrics.py`).

Chất lượng câu trả lời. Mô hình chấm tách câu trả lời thành các phát biểu đơn và xét từng phát biểu với *toàn văn* các đoạn nó trích: được hỗ trợ, hỗ trợ một phần, hoặc không được hỗ trợ. Đọc lại 5/5 phát biểu ngẫu nhiên và tra nguồn thấy khớp với bộ chấm. Bộ chấm chỉ xét phát biểu có căn cứ hay không, chưa xét phát biểu có trả lời đúng trọng tâm câu hỏi hay không.

5. Thực nghiệm phân loại

5.1 Môi trường và cấu hình

Thực nghiệm chạy trên máy Apple M2, Python 3.11, PyTorch, CPU. Hai mốc so sánh là mô hình luôn đoán lớp đông nhất và hồi quy logistic có trọng số lớp cân bằng. MLP có hai lớp ẩn 64 và 32 đơn vị:

$$h = \text{ReLU}(Wx + b), \qquad \text{ReLU}(a) = \max(0, a),$$

dropout 0,15, thuật toán Adam với tốc độ học 0,001, lô 512 dòng, tối đa 40 lượt học, dừng khi macro-F1 trên tập xác thực không tăng sau 7 lượt và khôi phục trọng số tốt nhất. Hàm mất

mát là cross entropy có trọng số $\ell_i = -w_{y_i} \log p_{i,y_i}$, trọng số lớp tỷ lệ nghịch với tần suất lớp trong tập huấn luyện. Toàn bộ năm seed của hai bài chạy trong 66 giây.

5.2 Chỉ số

Accuracy là tỷ lệ dự đoán đúng trên toàn bộ mẫu. Với một lớp, precision $= TP/(TP + FP)$ là tỷ lệ đúng trong các mẫu được dự đoán vào lớp đó, recall $= TP/(TP + FN)$ là tỷ lệ mẫu thật của lớp được tìm ra, và F1 là trung bình điều hòa của hai chỉ số này. Macro-F1 lấy trung bình F1 các lớp với trọng số ngang nhau, nên lớp ít mẫu có ảnh hưởng ngang lớp đông mẫu. Khi một lớp chiếm hơn 80% mẫu, accuracy có thể cao dù mô hình bỏ sót hoàn toàn các lớp còn lại, nên bài làm chọn mô hình và so sánh bằng macro-F1.

5.3 So sánh mô hình

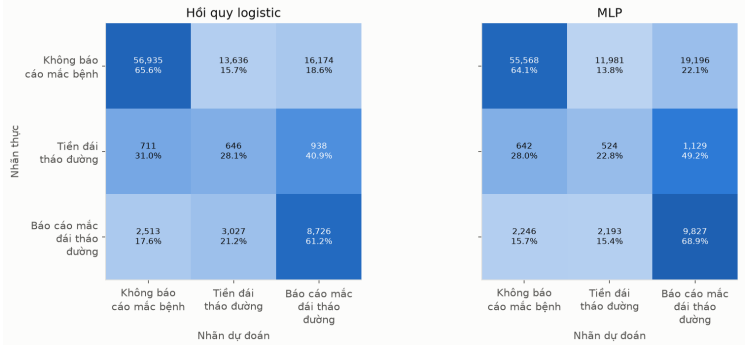
Mỗi mô hình được huấn luyện với 5 seed (0 đến 4). Mỗi seed vẽ lại cách chia tập, nên độ lệch chuẩn bao gồm cả dao động do chia tập.

Bảng 9: Kết quả trên tập kiểm tra, trung bình ± độ lệch chuẩn qua 5 seed

Mô hình	Accuracy	Macro-F1
Ba nhóm tình trạng		
Luôn lớp đông nhất	0,8392 ± 0,0007	0,3042 ± 0,0001
Hồi quy logistic	0,6431 ± 0,0018	0,4268 ± 0,0010
MLP	0,6423 ± 0,0035	0,4264 ± 0,0024
Type 1 / Type 2		
Luôn lớp đông nhất	0,9104 ± 0,0011	0,4765 ± 0,0003
Hồi quy logistic	0,6790 ± 0,0099	0,5223 ± 0,0074
MLP	0,7251 ± 0,0167	0,5436 ± 0,0063

Mô hình luôn đoán lớp đông nhất có accuracy cao nhất ở cả hai bài nhưng macro-F1 thấp nhất. Trọng số lớp đổi một phần accuracy lấy khả năng tìm ra các lớp ít mẫu. Ở bài ba nhóm, MLP và hồi quy logistic có macro-F1 chênh nhau ít hơn một độ lệch chuẩn, nên thí nghiệm không cho thấy MLP tốt hơn. Ở bài Type 1/2, MLP cao hơn logistic khoảng hai độ lệch chuẩn.

5.4 Kết quả ba nhóm khảo sát

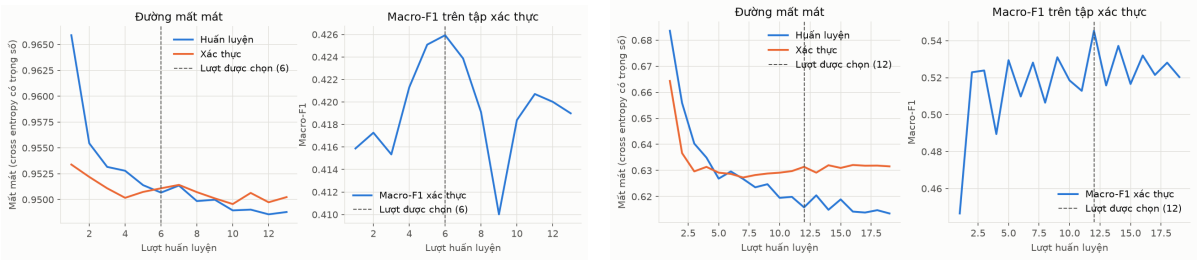


Hình 4: Ma trận nhầm lẫn trên tập kiểm tra ba nhóm (seed 0): hồi quy logistic (trái) và MLP (phải). Hàng là nhãn thật, cột là nhãn dự đoán.

Bảng 10: Chỉ số từng lớp của MLP (seed 0), bài ba nhóm

Lớp	Precision	Recall	F1	Số mẫu
Không báo cáo mắc bệnh	0,9506	0,6406	0,7654	86.745
Tiền đái tháo đường	0,0357	0,2283	0,0617	2.295
Báo cáo mắc đái tháo đường	0,3259	0,6888	0,4425	14.266

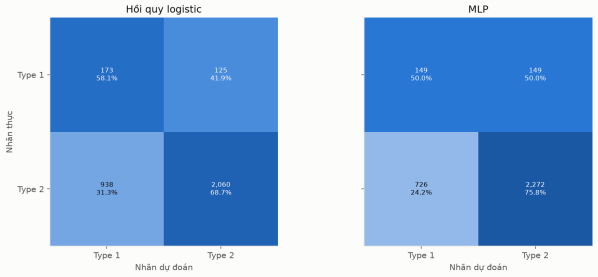
Lớp tiền đái tháo đường gần như không học được: mô hình nhận đúng 524 trên 2.295 mẫu, và chỉ 0,0357 số dự đoán vào lớp này là đúng. Đầu vào không có xét nghiệm đường huyết hay HbA1c, và nhãn lớp này phụ thuộc vào việc người trả lời đã từng được bác sĩ thông báo hay chưa, điều mà các đặc trưng hiện có không mô tả.



Hình 5: Sai số học, sai số xác thực và macro-F1 xác thực của MLP (seed 0): ba nhóm (trái), Type 1/2 (phải).

Ở bài ba nhóm, macro-F1 xác thực cao nhất ở lượt 5 và chương trình dừng ở lượt 13; ở bài Type 1/2 là lượt 11 và 19. Sai số học tiếp tục giảm trong khi sai số xác thực đi ngang, nên học thêm không cải thiện trên dữ liệu chưa thấy.

5.5 Kết quả Type 1 / Type 2



Hình 6: Ma trận nhầm lẫn bài Type 1/2 (seed 0): hồi quy logistic (trái) và MLP (phải).

Bảng 11: Chỉ số từng lớp của MLP (seed 0), bài Type 1/2

Lớp	Precision	Recall	F1	Số mẫu
Type 1	0,1703	0,5000	0,2540	298
Type 2	0,9385	0,7578	0,8385	2.998

Mô hình nhận đúng 149 trên 298 mẫu Type 1, nhưng trong 875 lần dự đoán Type 1 chỉ 0,1703 là đúng. Tỷ lệ báo động sai này cho thấy nhãn dự đoán không đủ tin cậy để kết luận loại bệnh của một người; hệ thống chỉ dùng nó để gợi ý chủ đề đọc.

5.6 Hiệu chỉnh xác suất

Xác suất đầu ra của mô hình được hiển thị trên giao diện, nên cần biết nó có phản ánh đúng tần suất thật hay không. ECE (expected calibration error) chia dự đoán thành 15 khoảng theo độ tự tin và lấy trung bình có trọng số của độ chênh giữa độ tự tin và tỷ lệ đúng trong từng khoảng. Temperature scaling chia điểm đầu ra cho một hằng số T chọn trên tập xác thực.

Bảng 12: ECE trên tập kiểm tra (MLP, seed 0)

Bài toán	T	Trước	Sau temperature scaling	Sau khi bỏ trọng số lớp
Ba nhóm	0,819	0,1116	0,0881	0,0056
Type 1/2	0,612	0,0962	0,0425	0,0237

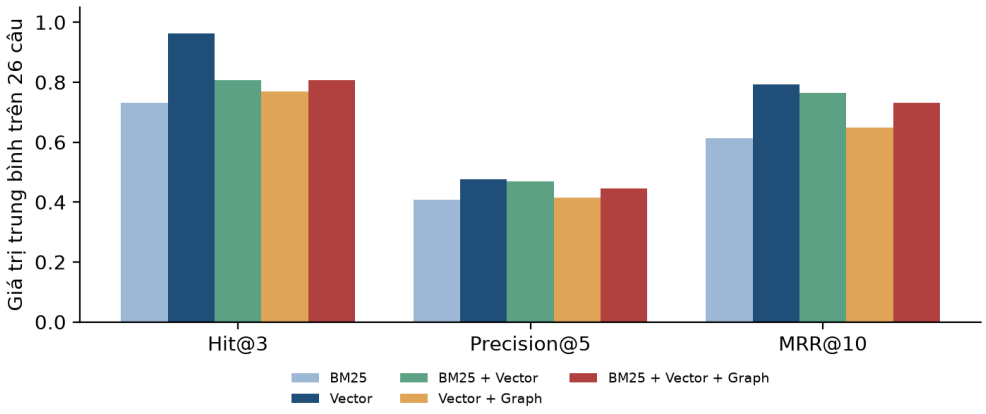
Temperature scaling giảm ECE nhưng không xóa được độ lệch do trọng số lớp gây ra: trọng số lớp cố ý đẩy xác suất về phía các lớp hiếm. Cột cuối là phép đo chẩn đoán, khi bỏ ảnh hưởng của trọng số lớp khỏi xác suất; ECE giảm rõ. Giao diện hiện dùng xác suất sau temperature scaling, và kèm lời nhắc rằng đây không phải kết quả chẩn đoán.

6. Kết quả hỏi đáp

6.1 So sánh các cách truy xuất

Bảng 13: Truy xuất trên 26 câu trong phạm vi, xếp hạng 10 đoạn, không mở rộng

Cấu hình	Hit@3	Hit@5	Precision@5	Recall@5	MRR@10
BM25	0,731	0,846	0,408	0,425	0,613
Vector	0,962	1,000	0,477	0,498	0,792
BM25 + Vector	0,808	0,923	0,469	0,486	0,765
Vector + Graph	0,769	0,923	0,415	0,435	0,648
BM25 + Vector + Graph	0,808	0,923	0,446	0,464	0,731



Hình 7: Ba chỉ số truy xuất theo cấu hình.

Vector đứng đầu ở mọi chỉ số; năm đoạn đầu chứa ít nhất một đoạn liên quan ở tất cả 26 câu. Thêm BM25 làm kết quả kém đi. BM25 tách tiếng Việt theo âm tiết, và các âm tiết như "đái", "tháo", "đường" xuất hiện ở hầu hết mọi đoạn nên đóng góp nhiều nhiễu. Thêm đồ thị vào

RRF như một nhánh ngang hàng cũng làm kết quả kém đi: nhánh đồ thị trả về các đoạn hỗ trợ cùng dữ kiện, nhưng "cùng dữ kiện" không có nghĩa là "trả lời cùng câu hỏi", và các đoạn này đẩy đoạn tốt của vector xuống dưới.

Cần lưu ý một điểm về cách đo. Tập tham chiếu được gộp từ 20 đoạn đầu của mọi nhánh, nên không thiên về một nhánh nào ở bước chọn ứng viên; nhưng bộ chấm và bộ biểu diễn đều là mô hình học sâu, và đoạn được vector xếp cao có thể cũng dễ được bộ chấm coi là liên quan.

6.2 Đóng góp của đồ thị

Đồ thị được dùng theo cách khác: nối thêm tối đa 2 đoạn sau 5 đoạn đầu của vector. Trên 26 câu, đồ thị thêm 51 đoạn; 17,6% trong số đó liên quan đến câu hỏi, 39,2% là đoạn ở ngôn ngữ còn lại, và 7 đoạn liên quan nằm ngoài 10 đoạn đầu của vector, tức là vector không tìm được.

Bảng 14: Câu trả lời có và không có mở rộng bằng đồ thị

Chỉ số	Không mở rộng	Mở rộng 2 đoạn
Câu trong phạm vi được trả lời	24/26	25/26
Số phát biểu được chấm	175	186
Phát biểu được nguồn hỗ trợ	98,9%	97,9%
Phát biểu không được hỗ trợ	0,6%	0,0%
Từ chối nhầm câu trong phạm vi	7,7%	3,9%

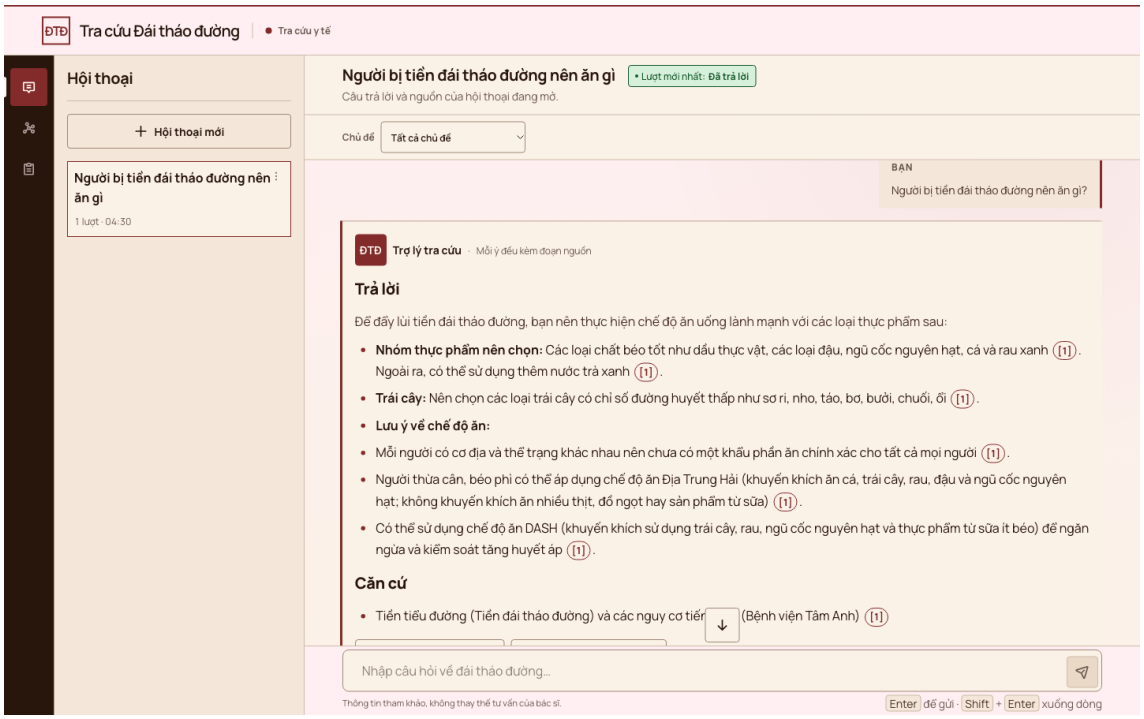
Hai cấu hình chênh nhau một câu hỏi trên một lần chạy, nên thí nghiệm không cho thấy đồ thị cải thiện câu trả lời một cách đo được. Kết quả cho thấy việc mở rộng không làm câu trả lời kém đi và có đưa thêm bằng chứng từ ngôn ngữ còn lại, nên cấu hình chạy thật giữ lại bước mở rộng.

6.3 Chất lượng câu trả lời

Với cấu hình chạy thật, hệ thống trả lời 25/26 câu trong phạm vi, từ chối đúng 100% câu ngoài phạm vi, và 97,9% phát biểu được nguồn trích dẫn hỗ trợ. Thời gian một câu có trung vị 2,46 giây, lâu nhất 8,82 giây, phần lớn là thời gian mô hình ngôn ngữ viết câu trả lời.

Các lỗi đã tìm ra trong quá trình đo. Số liệu trên là kết quả sau ba vòng đo và sửa; hai vòng đầu là lỗi của hệ thống đo và của cổng trích dẫn, không phải của mô hình.

1. Lần đo đầu cho 39,1% phát biểu không được hỗ trợ. Nguyên nhân là bộ chấm chỉ nhận 600 ký tự đầu của mỗi nguồn, trong khi một đoạn dài hơn nhiều. Sau khi cho bộ chấm đọc toàn văn, tỷ lệ này còn 4,0%.
2. Tỷ lệ từ chối nhầm câu trong phạm vi khi đó là 19,2%. Đọc đầu ra thô cho thấy mô hình viết trích dẫn dạng `[[S5]]`, `[[1, 3, 5]]` hay `[[S2, S4]]`, và cổng trích dẫn xóa hết vì không khớp dạng `[[cite:S5]]`. Sau khi cổng chuẩn hóa các cách viết này, tỷ lệ từ chối nhầm còn 3,9%.



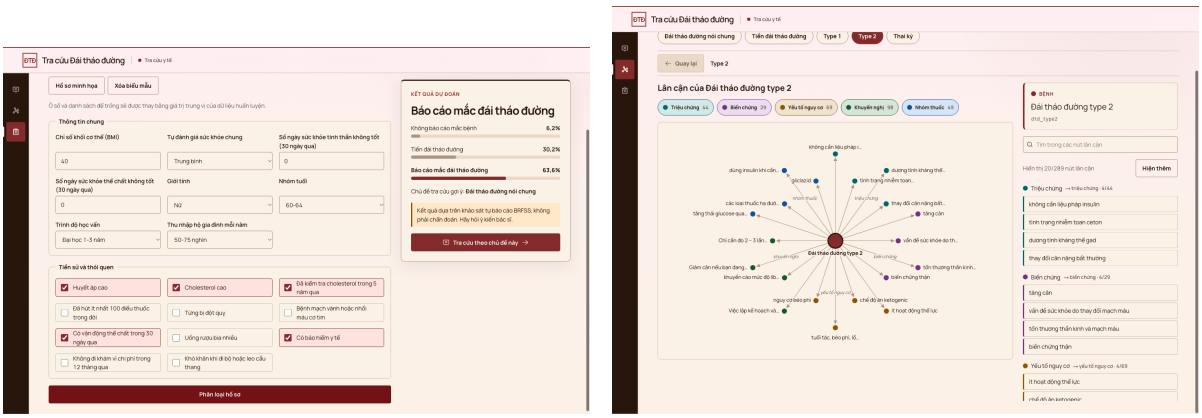
Hình 8: Giao diện hỏi đáp chạy với dữ liệu thật: câu trả lời có trích dẫn đánh số, phần căn cứ ghi tài liệu và đơn vị xuất bản.

7. Tích hợp và thảo luận

7.1 Phân loại và chọn chủ đề

Nhãn dự đoán được chuyển thành chủ đề qua một bảng duy nhất trong `schema.py`: nhãn 0 thành chủ đề phòng ngừa, nhãn 1 thành tiền đái tháo đường, nhãn 2 thành đái tháo đường nói chung, Type 1 và Type 2 thành chủ đề tương ứng. Kiểm thử khẳng định mọi nhãn mà bộ phân loại có thể trả ra đều có trong bảng. Trên trang phân loại, nút "Tra cứu theo chủ đề này" mở trang hỏi đáp với chủ đề đã chọn; chủ đề được truyền vào bước mở rộng đồ thị để lấy thêm các đoạn hỗ trợ dữ kiện của bệnh tương ứng.

Với hồ sơ minh họa BMI 40, nhóm tuổi 9 (60–64 tuổi), huyết áp cao và cholesterol cao, mô hình ba nhóm dự đoán nhãn 2 (báo cáo mắc đái tháo đường) và hệ thống mở chủ đề đái tháo đường nói chung. Nhãn này không xác định Type 1 hay Type 2; bài Type 1/2 dùng mô hình và đầu vào riêng, chỉ có nghĩa với người đã báo cáo mắc bệnh.



Hình 9: Trang phân loại với hồ sơ minh họa (trái) và trang đồ thị tri thức quanh nút đái tháo đường típ 2 (phải). Bấm một nút lân cận để đi tiếp tới khuyến nghị, đoạn văn và tài liệu nguồn.

Đo trên giao diện bằng trình duyệt tự động, thời gian từ lúc bấm gửi đến khi chữ đầu tiên xuất hiện có trung vị 2,9 giây trên 5 câu hỏi; phần lớn là thời gian gọi mô hình ngôn ngữ.

7.2 Giới hạn và hướng phát triển

Dữ liệu và đánh giá. Nhãn khảo sát là tự báo cáo, không có xét nghiệm xác nhận, và các chỉ số chưa dùng trọng số thiết kế của BRFSS nên chỉ mô tả mẫu, không ước lượng cho dân số. Bộ đánh giá RAG có 30 câu và tập tham chiếu do mô hình ngôn ngữ gán; đọc lại mẫu cho thấy khoảng 12/15 nhãn đúng. Một số chênh lệch nhỏ giữa các cấu hình (một câu hỏi) nằm trong mức dao động của một lần chạy. Hệ thống chưa được chuyên gia y tế đánh giá.

Đồ thị. Việc gộp dữ kiện còn yếu do tên ngắn không thống nhất, nên số dữ kiện được hai ngôn ngữ cùng hỗ trợ còn ít. Hướng tiếp theo là gộp dữ kiện bằng độ gần vector của tên và câu trích, sau đó đo lại đóng góp của bước mở rộng. Phân loại loại dữ kiện cũng cần một bước kiểm riêng.

Thời gian phản hồi. Vì cổng trích dẫn chạy trên toàn bộ câu trả lời, chữ đầu tiên chỉ xuất hiện khi mô hình đã viết xong. Có thể kiểm từng câu khi mô hình viết tới dấu chấm để hiện chữ sớm hơn mà vẫn giữ nguyên quy tắc không hiện ý chưa qua kiểm tra.

8. Kết luận

Bài làm dựng được một hệ thống tra cứu đái tháo đường chạy được từ đầu đến cuối: 35 tài liệu hai ngôn ngữ được tổ chức thành đồ thị Neo4j, câu trả lời luôn chỉ về đoạn nguồn cụ thể, và hệ thống từ chối khi không có bằng chứng. Trên bộ kiểm tra, 97,9% phát biểu được nguồn hỗ trợ và cả 4 câu ngoài phạm vi đều bị từ chối.

Hai kết quả đo đáng chú ý đi ngược kỳ vọng ban đầu. Thứ nhất, xếp hạng chỉ bằng vector tốt hơn mọi cách gộp với BM25 và đồ thị; đồ thị có ích hơn khi dùng để bổ sung ngữ cảnh và bằng chứng ở ngôn ngữ khác. Thứ hai, phần lớn lỗi lớn trong quá trình làm nằm ở hệ thống đo và ở bước xử lý định dạng trích dẫn, không ở mô hình; cả hai chỉ lộ ra khi đọc đầu ra thô thay vì tin con số tổng hợp.

Bộ phân loại khảo sát nhận diện kém các nhóm ít mẫu: lớp tiền đái tháo đường gần như không học được, và dự đoán Type 1 có tỷ lệ báo động sai cao. Nhãn dự đoán vì vậy chỉ dùng để gợi ý chủ đề đọc, không dùng để kết luận tình trạng của một người.

9. Tài liệu tham khảo

[1] CDC. Behavioral Risk Factor Surveillance System, 2023 Annual Survey Data. `https://www.cdc.gov/brfss/annual_data/annual_2023.html`.

[2] Bộ Y tế. Quyết định 5481/QĐ-BYT ngày 30/12/2020 ban hành tài liệu chuyên môn "Hướng dẫn chẩn đoán và điều trị đái tháo đường típ 2".

[3] NIDDK. Diabetes overview. `https://www.niddk.nih.gov/health-information/diabetes`.

[4] WHO. Diabetes fact sheet. `https://www.who.int/news-room/fact-sheets/detail/diabetes`.

[5] Neo4j. Cypher Manual, Vector indexes. `https://neo4j.com/docs/cypher-manual/current/indexes/semantic-indexes/vector-indexes/`.

[6] Chen J. và cộng sự. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings. 2024. `https://huggingface.co/BAAI/bge-m3`.

[7] Cormack G., Clarke C., Büttcher S. Reciprocal Rank Fusion outperforms Condorcet and individual rank learning methods. SIGIR 2009.

[8] Guo C. và cộng sự. On Calibration of Modern Neural Networks. ICML 2017.

[9] Lewis P. và cộng sự. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020.

Danh sách đầy đủ 35 tài liệu trong kho tri thức, kèm địa chỉ và ngày tải, nằm trong `data/processed/documents.jsonl` và `pipeline/sources.yaml`.